

১) Column Transformer কী এবং কেন দরকার?

বাস্তব ডেটাসেটে এক ধরনের কলাম থাকে না। সাধারণত থাকে:

1. Numerical column
 - বয়স, তাপমাত্রা, আয়
 - এখানে missing value থাকতে পারে
 - অনেক সময় scaling দরকার হয়
2. Nominal categorical column
 - Gender, City, Brand
 - কোনো natural order নেই
 - সাধারণত One-Hot Encoding লাগে
3. Ordinal categorical column
 - Review: Poor < Average < Good
 - Cough: Mild < Strong
 - OrdinalEncoder লাগে (অর্ডার বলে দিতে হয়)

সমস্যা হলো: এই তিন ধরনের কলামের preprocessing এক রকম নয়।

আগে মানুষ যেটা করত:

- Numerical কলাম আলাদা করে impute/scale
- Nominal কলাম আলাদা করে one-hot
- Ordinal কলাম আলাদা করে ordinal encode
- তারপর সব আউটপুট array হাতে জোড়া লাগাতে হতো (concatenate)

এখানে তিনটা বড় সমস্যা হয়:

- কোড অনেক বড় হয়
- column order mismatch হতে পারে
- train-test এ consistency নষ্ট হতে পারে (বিশেষ করে one-hot এ)

Column Transformer এই সমস্যার “স্ট্যান্ডার্ড” সমাধান।

২) Column Transformer এর মূল ধারণা (Core Concept)

ColumnTransformer হলো এমন একটি কন্টেইনার, যেখানে আপনি বলে দেন:

- কোন transformer কোন কলামে লাগবে
- বাকিগুলো কী হবে (রাখবেন নাকি বাদ দেবেন)

তারপর আপনি একবার `fit` এবং `transform` করলে এটি:

- প্রতিটি কলামকে নির্দিষ্ট নিয়মে প্রসেস করবে
- সব আউটপুট একত্র করে একটি final numeric feature matrix বানিয়ে দেবে

অর্থাৎ, “একই ডেটাসেট থেকে একসাথে সব preprocessing”।

৩) উদাহরণটা বাস্তবভাবে কী বোঝায়?

৫টা কলাম ছিল (COVID patient dataset):

- Fever: numerical বা mixed, missing আছে
সমাধান: SimpleImputer (mean/median/most_frequent যেটা দরকার)
- Cough: Mild/Strong (Ordinal)
সমাধান: OrdinalEncoder (Mild < Strong)
- Gender, City: Nominal
সমাধান: OneHotEncoder
- Age: পরিবর্তন লাগবে না
সমাধান: 그대로 রেখে দেওয়া (passthrough) অথবা বাদ দেওয়া (drop) — যেটা প্রয়োজন

এই সবকে এক জায়গায় বসিয়ে দেওয়া হয় ColumnTransformer দিয়ে।

৪) ColumnTransformer কীভাবে বানানো হয়?

ColumnTransformer তৈরি করার সময় মূলত দুইটা জিনিস ঠিক করতে হয়:

(A) Transformers list (সবচেয়ে গুরুত্বপূর্ণ)

এটা একটি list; প্রতিটি item একটি tuple:

(name, transformer_object, columns)

এখানে:

- name: আপনি নিজের মতো একটি নাম দেবেন (শুধু identify করার জন্য)
- transformer_object: যেমন
SimpleImputer/OneHotEncoder/OrdinalEncoder/StandardScaler ইত্যাদি
- columns: কোন কোন কলামে এটা লাগবে (কলামের নাম বা index)

এই অংশটাই বলে দেয় “কোন কলামে কী preprocessing হবে”।

(B) remainder (অবশিষ্ট কলামগুলোর আচরণ)

আপনি যেসব কলামকে transformers list-এ উল্লেখ করেননি, তাদের কী হবে?

- `remainder='passthrough'`
মানে: ওই কলামগুলো যেমন আছে, তেমনই final output-এ যোগ হবে
উদাহরণ: Age 그대로 রাখতে চাইলে
- `remainder='drop'` (ডিফল্ট সাধারণত drop)
মানে: উল্লেখ না করা কলামগুলো বাদ যাবে

এটা গুরুত্বপূর্ণ কারণ বড় ডেটাসেটে আপনি সব কলামের জন্য আলাদা transformer দেবেন না; কিছু কলাম “যেমন আছে” রাখতে চাইবেন।

৫) Fit/Transform এর নিয়ম (train-test consistency)

ColumnTransformer ব্যবহার করলেও নিয়ম একই:

1. Train-test split আগে
2. `fit` শুধু train data তে
3. `transform` train এবং test—দুটোতেই

এটার লাভ:

- OneHotEncoder train set থেকে categories শিখবে
- test set এ consistent feature columns তৈরি হবে
- leakage হবে না

৬) কেন এটাকে “সময় সাশ্রয়ী” বলা হয়?

কারণ এটা ৩টা কঠিন কাজ একসাথে করে:

1. বিভিন্ন ধরনের preprocessing একত্রে চালায়
2. output array গুলো নিজে থেকেই জোড়া লাগায়
3. train-test এ consistent transformation নিশ্চিত করে

যেখানে আগে:

- তিন জায়গায় আলাদা code
- concatenate

- column mismatch debugging
লাগত, এখন এক জায়গায় declarative ভাবে বলে দিলেই হয়।

৭) বাস্তব প্রজেক্টে ColumnTransformer কেন জরুরি?

যখন:

- ৫০/১০০+ কলাম থাকে
- নানা ধরনের preprocessing লাগে
- production/pipeline এ model deploy করবেন
- cross-validation করবেন

তখন ColumnTransformer ছাড়া কাজ করা মানে:

- বেশি manual code
- ভুল হওয়ার সম্ভাবনা বেশি
- reproducibility কমে যায়

ColumnTransformer সহজ করে দেয়:

- clean pipeline build
- maintainability
- scaling up to large datasets

৮) বাস্তব best practices (শুধু ধারণা নয়, কাজের নিয়ম)

1. OneHotEncoder এ সাধারণত `handle_unknown` ব্যবহার করা হয়
কারণ test/production এ নতুন category আসতে পারে
2. OrdinalEncoder এ categories order স্পষ্ট করে দিন
না হলে ভুল order শিখতে পারে
3. ColumnTransformer সাধারণত Pipeline এর ভেতরে বসানো হয়
যাতে preprocessing + model একসাথে fit/transform হয় এবং ভুল কমে

৯) সারসংক্ষেপ

ColumnTransformer হলো এমন একটি preprocessing controller, যা আপনাকে এক জায়গায় বলে দিতে দেয়:

- কোন কলামে কোন transformation হবে
- বাকি কলাম রাখবেন নাকি বাদ দেবেন

এবং শেষে সব প্রসেস করা কলাম মিলিয়ে একটি final numeric feature matrix তৈরি করে দেয়, যা সরাসরি মডেলে যায়।