

# টপিক

Numerical ডেটাকে Category ডেটায় রূপান্তর করা

Feature Engineering-এর ভাষায় একে Discretization বা Binning বলা হয়  
এর বিশেষ কেস হলো Binarization, যেখানে আউটপুট শুধু 0 বা 1

## 1) Discretization বা Binning কী

Continuous numerical value কে কিছু নির্দিষ্ট interval বা bin-এ ভাগ করা  
ফলে সংখ্যাটা সরাসরি ব্যবহার না করে সেটাকে একটি category হিসেবে দেখা হয়

উদাহরণ

Age: 4, 17, 23, 45, 62, 80

Binning করলে হতে পারে

0–10 Child

10–20 Teen

20–40 Adult

40+ Senior

এখন Age আর raw number না, বরং একটি label বা category

## 2) কেন Binning করা হয়

**Outlier** হ্যান্ডেল করতে

Outlier মানে অস্বাভাবিক বড় বা ছোট মান

যেমন Titanic ডেটায় Fare = 512

Raw numeric রাখলে মডেল এই extreme মানকে বেশি গুরুত্ব দিতে পারে

Binning করলে 512 একটি High Fare টাইপ bin-এ পড়ে যায়

ফলে negative influence কমে

ডেটার **distribution** বা **spread** উন্নত করতে

ডেটা অনেক সময় skewed থাকে

Quantile binning করলে প্রতিটি bin-এ প্রায় সমান সংখ্যক ডেটা পড়ে

ফলে model stable signal পেতে পারে

কিছু মডেলে শেখা সহজ করতে

কিছু ক্ষেত্রে raw numeric সম্পর্ক non-linear হয়

Bins বানালে feature একধরনের step-like behavior তৈরি করে

এতে group-based pattern ধরতে সুবিধা হতে পারে

তবে trade-off আছে

Binning করলে precision কিছুটা কমে, কারণ exact value হারিয়ে যায়

### 3) Binning-এর ৩টি জনপ্রিয় কৌশল

#### 3.1 Equal Width বা Uniform Binning

পুরো range কে সমান প্রস্থে ভাগ করা

Formula

Bin width =  $(\text{max} - \text{min}) / \text{number of bins}$

উদাহরণ

Age min=0, max=80, bins=4

width =  $(80-0)/4 = 20$

Bins: 0–20, 20–40, 40–60, 60–80

কখন ভালো

ডেটা যদি মোটামুটি evenly spread হয়

কখন সমস্যা

ডেটা যদি skewed হয়, অনেক ডেটা এক bin-এ গাদাগাদি হয়ে যায়

#### 3.2 Equal Frequency বা Quantile Binning

প্রতিটি bin-এ প্রায় সমান সংখ্যক data point রাখার চেষ্টা

উদাহরণ

100 data, bins=4

প্রতি bin-এ প্রায় 25টা করে data

কখন ভালো

Outlier ও skewed distribution-এর ক্ষেত্রে ভালো কাজ করে

Distribution balanced হয়

কখন সীমাবদ্ধতা

Bins-এর width সমান থাকে না

কোথাও ছোট range, কোথাও বড় range হতে পারে

#### 3.3 KMeans Binning

KMeans clustering ব্যবহার করে natural group অনুযায়ী bins তৈরি

কখন ভালো

ডেটা যদি naturally cluster তৈরি করে বা multi-modal হয়

কখন সীমাবদ্ধতা

ফল dataset এবং initialization-এর উপর sensitive হতে পারে  
Interpretability অনেক সময় কমে

## 4) Custom Binning

Domain knowledge ব্যবহার করে নিজের মতো bins বানানো

উদাহরণ

Age < 18 Child

18–60 Adult

60 Retired

সুবিধা

Interpretability বেশি

Business rule অনুযায়ী align করা যায়

ঝুঁকি

ভুল rule হলে bias বা ভুল decision boundary তৈরি হতে পারে

## 5) Binarization

Discretization-এর বিশেষ রূপ

আউটপুট শুধু 2টা class: 0 এবং 1

Mechanism

একটা threshold সেট করা হয়

$x \leq \text{threshold}$  হলে 0

$x > \text{threshold}$  হলে 1

উদাহরণ

Income > 6 lakh হলে Tax payer = 1

নাহলে 0

Use case

Image processing-এ grayscale থেকে black-white conversion

Simple and fast, তবে threshold ভুল হলে signal নষ্ট হতে পারে

## 6) Scikit-learn দিয়ে ধারণাগতভাবে কী করা হয়

**KBinsDiscretizer**

Key parameters

n\_bins: কয়টা bin

strategy: uniform, quantile, kmeans

encode: ordinal বা onehot

encode কেন গুরুত্বপূর্ণ

ordinal হলে bin label 0,1,2 হিসেবে আসে

onehot হলে প্রতিটি bin আলাদা feature column হয়

অনেক মডেলে onehot উপকারী হতে পারে

## Binarizer

threshold সেট করলেই 0/1 তৈরি

## 7) Titanic ডেটায় accuracy কেন বাড়তে পারে

Age এবং Fare অনেক সময় non-linearভাবে target-এর সাথে সম্পর্কিত

যেমন মাঝারি বনাম খুব বেশি Fare এই পার্থক্যটা বেশি গুরুত্বপূর্ণ হতে পারে

Age-এও child, adult, senior গ্রুপভিত্তিক pattern কাজ করতে পারে

Binning করলে এই group signal স্পষ্ট হয়

তাই কখনো performance উন্নতি দেখা যায়

## 8) কখন ব্যবহার করবে, কখন এড়াবে

ব্যবহার করা ভালো যখন

ডেটা skewed বা outlier-heavy

Interpretability দরকার

Non-linear relation সন্দেহ হচ্ছে

ডেটা ছোট এবং noisy

এড়ানো ভালো যখন

Exact numeric precision দরকার, যেমন regression price prediction

Feature খুব smooth এবং ইতিমধ্যেই predictive

Bins ভুল হলে performance drop করতে পারে